



**Università degli Studi di Milano
Bicocca**

Dipartimento di Informatica, Sistemistica e
Comunicazione

Corso di Laurea Magistrale in Informatica

Machine Learning

Valutazione qualità dei vini

Studente: Ion Pirnau

Matricola: 887465

Anno Accademico: 2025-2026

Abstract

Utilizzando un dataset reperito dal sito [3], sono stati implementati due modelli di classificazione supervisionata: Support Vector Machine ed il Decision Tree. L'obiettivo dell'analisi è valutare quale dei due modelli risulta essere più efficace nella classificazione degli elementi del dataset, sulla base delle feature e del target forniti.

Sommario

1	Introduzione	4
1.1	Dataset	4
1.2	Obiettivo	4
1.3	Ambiente di sviluppo	4
2	Wine Quality	5
2.1	Descrizione	5
3	Modelli	6
3.1	Decision Tree (DT)	6
3.2	Support Vector Machine (SVM)	6
4	Metodo	7
4.1	Strategia di Modellazione	7
4.2	Terminologie - metriche	7
4.3	Analisi preliminare	8
4.4	SVM	8
4.4.1	Kernel	8
4.4.2	Tipologia Kernel	9
4.4.3	Confronto tra Kernel	10
4.4.4	C	10
4.5	Kernel: Linear	11
4.5.1	Training e Test - <i>Wine Quality</i>	12
4.5.2	Considerazioni sui risultati ottenuti	14
4.5.3	Confronto: Modello Completo vs Ridotto	15
4.5.4	Valutazione SVM Lineare - Classificazione Multiclasse	16
4.6	Kernel: RBF	19
4.6.1	Training e Test - <i>Wine Quality</i>	20
4.6.2	Valutazione	22
4.6.3	Valutazione SVM rbf - Classificazione Multiclasse	23
4.6.4	Metriche di Classificazione	25
4.6.5	Osservazioni	26
4.7	Kernel: Poly	26
4.7.1	Prestazioni	26
4.7.2	Considerazioni	27
4.8	Decision Tree (DT)	28
4.8.1	Configurazione del Modello Decision Tree	28
4.9	Classificazione Binaria - (DT)	29
4.9.1	Osservazioni	30

4.10	Classificazione Muticlasse - (DT)	31
4.10.1	Osservazioni	33
5	Conclusioni	34
5.1	Classificazione Multiclasse vs Binaria	34
5.1.1	Riflessione Finale	35
5.2	Considerazioni: SVM	36
5.3	Considerazioni: Decision Tree	36
5.4	SVM vs Decision Tree	36
	Bibliografia	38

1 Introduzione

I modelli di classificazione supervisionata hanno un ruolo fondamentale nell'analisi e interpretazione dei dati. Si analizzano due algoritmi ampiamente conosciuti: **Support Vector Machine (SVM)** e **Decision Tree (DT)**, applicati a un dataset pubblico reperito da [3].

1.1 Dataset

Verrà utilizzato il dataset '*Wine Quality*' [1] per addestrare due modelli di apprendimento supervisionato per classificare la qualità del vino.

1.2 Obiettivo

L'obiettivo è confrontare le performance dei due modelli nel processo di classificazione, valutando la loro efficacia in funzione delle caratteristiche (feature) e del target forniti nel dataset selezionato; inoltre riuscire ad avere un modello che classifichi '*correttamente*' i vini sia di qualità superiore e non.

1.3 Ambiente di sviluppo

Il codice è stato sviluppato interamente in *Python*[2], avvalendosi dell'ambiente interattivo fornito dal notebook *Jupyter*.

2 Wine Quality

Wine Quality è il dataset utilizzato per l'addestramento dei due modelli di apprendimento supervisionato.

2.1 Descrizione

Il dataset fornisce due sottoinsiemi distinti per vino rosso e vino bianco, relativi a campioni di vino *Vinho Verde* provenienti dal nord del Portogallo.

Sono presenti le seguenti istanze:

- **Vino rosso:** 1599 campioni
- **Vino bianco:** 4898 campioni

Ciascun sotto-dataset è composto da:

- **11 variabili indipendenti** (feature) che descrivono le proprietà chimico-fisiche del vino;
- **1 variabile dipendente** (target), la qualità del vino, espressa come valore intero compreso tra 0 e 10, basata su valutazioni sensoriali da parte di esperti.

Feature

- Acidità fissa
- Acidità volatile
- Acido citrico
- Zuccheri residui
- Cloruri
- Anidride solforosa libera e totale
- Densità
- pH
- Solfati
- Alcol

Target

- Qualità

3 Modelli

In questa sezione viene riportata una breve descrizione dei modelli che si andranno ad utilizzare.

3.1 Decision Tree (DT)

Il *Decision Tree* è un modello di apprendimento supervisionato utilizzato sia per la classificazione che per la regressione. L'algoritmo costruisce una struttura ad albero che suddivide i dati in base a regole decisionali sulle variabili di input. Ogni nodo interno rappresenta una condizione su una feature, mentre le foglie corrispondono a una classe o a un valore stimato. Questo metodo è intuitivo e facilmente interpretabile, ma può essere soggetto a overfitting se non regolato correttamente.

3.2 Support Vector Machine (SVM)

Il *Support Vector Machine (SVM)* è un algoritmo di apprendimento supervisionato che trova un iperpiano ottimale in uno spazio multidimensionale per separare le classi. L'obiettivo è massimizzare il margine tra le classi, rendendo il modello robusto anche in presenza di dati non linearmente separabili. Attraverso l'utilizzo di funzioni kernel, SVM può proiettare i dati in spazi più complessi per trovare frontiere decisionali anche non lineari. È efficace in spazi ad alta dimensionalità, ma può risultare computazionalmente oneroso e sensibile alla scelta dei parametri.

4 Metodo

In questa sezione, analizzeremo per ognuno dei modelli sviluppati la loro pipeline interna, i risultati ottenuti e le feature importanti (scoperte durante l'esecuzione).

4.1 Strategia di Modellazione

L'idea alla base è costruire dei modelli predittivi in grado di valutare *'accuratamente'* la qualità dei vini sulla base delle loro proprietà chimico-fisiche, sfruttando le informazioni apprese durante il training.

La scelta di unire i due dataset, relativi a:

- **vino rosso**,
- **vino bianco**,

nasce dalla volontà di sviluppare un modello universale, capace di cogliere gli indicatori di qualità indipendentemente dal tipo di vino.

4.2 Terminologie - metriche

Piccola sezioni di teoria per spiegare il tipo di metriche utilizzate e utili a determinare l'accuratezza, correttezza e precisione dei modelli.

ROC Receiver Operating Characteristic, è una curva che mostra il trade-off tra

- True Positive Rate (Recall);
- False Positive Rate (Specificity);

al variare della soglia di classificazione;

AUC Area Under the Curve, è il valore numerico (da 0 a 1) che rappresenta quanto il modello è capace di separare correttamente le classi

- Valori vicini a 1.0 → classificazione eccellente
- Valori intorno a 0.5 → classificazione casuale (come tirare a sorte)

4.3 Analisi preliminare

Prima di procedere con la costruzione e l'addestramento del modello, vogliamo fare una prima analisi sulle feature che il modello utilizzerà per definire e predire il target.




Figure 1: Heatmap, correlazione di Pearson sulla qualità del vino

La Figura 1 mostra la correlazione di Pearson i cui valori vanno da:

- $+1 \rightarrow$ perfetta correlazione positiva: al crescere di $\mathbf{X}$, cresce $\mathbf{Y}$,
- $0 \rightarrow$ nessuna correlazione lineare,
- $-1 \rightarrow$ perfetta correlazione negativa: al crescere di $\mathbf{X}$, diminuisce $\mathbf{Y}$,

Lo scopo della tabella è mostrare quanto le feature influenzano (o il loro grado di relazione 'lineare') il target **Quality** (*Qualità*)

Limite: se la relazione è non lineare, la correlazione può risultare bassa anche se la feature è importante! Questo limite lo si scoprirà con metodi che verranno descritti più tardi.

4.4 SVM

4.4.1 Kernel

È importante dare una definizione di che cosa è e le caratteristiche dei principali tipi di Kernel.

Definizione

Il **kernel** è una funzione che consente di trasformare i dati originali in uno spazio di caratteristiche di dimensione superiore, dove è più probabile che diventino linearmente separabili. Questo approccio è noto come *kernel trick*, permette di eseguire questa trasformazione implicitamente, senza dover calcolare le nuove coordinate dei punti nello spazio trasformato.

$$K(x, x') = \langle \phi(x), \phi(x') \rangle$$

Dove

- $\phi(\cdot)$ è la mappa di trasformazione verso lo spazio delle caratteristiche,
- $\langle \cdot, \cdot \rangle$ è il prodotto scalare

4.4.2 Tipologia Kernel

Kernel Lineare Il kernel lineare non trasforma lo spazio: usa direttamente il prodotto scalare tra vettori nel loro spazio originale.

$$K(x, x') = x^\top x'$$

Vantaggi:

- Ideale quando i dati sono già linearmente separabili.
- Semplice e computazionalmente poco costoso.

Kernel Polinomiale (Poly) Mappa i dati in uno spazio polinomiale di grado d . Può catturare relazioni non lineari.

$$K(x, x') = (\gamma x^\top x' + r)^d$$

Dove

- $\gamma > 0$ è un parametro di scaling,
- $r \in \mathbb{R}$ è un termine di bias,
- d è il grado del polinomio

Vantaggi:

- Utile quando si sospetta che la relazione tra i dati sia polinomiale..
- Può modellare decision boundaries molto flessibili.

Kernel RBF (Radial Basis Function) (detto anche Gaussian Kernel) Proietta i dati in uno spazio di infinite dimensioni. È altamente efficace per catturare relazioni complesse.

$$K(x, x') = \exp(-\gamma \|x - x'\|^2)$$

Dove

- $\gamma > 0$ controlla l'influenza di un singolo campione

Vantaggi:

- Molto usato per classificazione non lineare.
- Non presuppone una forma della frontiera di decisione

4.4.3 Confronto tra Kernel

Tipo di Kernel	Linearità	Parametri Principali	Applicazioni
Lineare	Lineare	Nessuno	Dati separabili linearmente
Polinomiale	Non lineare	γ, r, d	Relazioni polinomiali tra caratteristiche
RBF	Non lineare	γ	Complessità non lineare, pattern invisibili

Table 1: Confronto tra diverse tipologie di kernel per SVM

4.4.4 C

Il parametro C in una Support Vector Machine (SVM) è fondamentale per determinare l'equilibrio tra massimizzazione del margine e minimizzazione dell'errore di classificazione sui dati di training.

Parametro C Il parametro $C > 0$ controlla quanto penalizzare gli errori di classificazione. Formalmente, entra nella funzione obiettivo dell'SVM come termine di regolarizzazione:

$$\min_{w, b, \xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

Dove

- w e b definiscono l'iperpiano di separazione;
- ξ sono le variabili di slack (che permettono la violazione del margine);
- C bilancia tra la larghezza del margine e l'entità delle violazioni

Valore di C	Effetto sul Modello	Comportamento
Alto ($C \gg 1$)	Penalizzazione severa degli errori	Il modello cerca di classificare correttamente ogni punto, ma può sovradattarsi
Basso ($C \ll 1$)	Errori più tollerati	Il modello privilegia un margine più ampio, favorendo la generalizzazione, ma con possibile sottoadattamento

Table 2: Effetti del parametro di regolarizzazione C nelle SVM

4.5 Kernel: Linear

Dopo una breve introduzione dei concetti di teoria, la domanda che ci dobbiamo porre:

Quale kernel utilizzare?

Osservando il dataset e la relazione tra le feature in Figura 1, a prima vista sembrerebbe che l'alcool sia la feature più importante e quindi si è scoperto una relazione 'lineare' tra le feature. L'obiettivo adesso analizzare quale Kernel risulta essere migliore per il dataset [1].

4.5.1 Training e Test - *Wine Quality*

Informazioni

Labelling: binario

- $0 \rightarrow$ vino cattivo (≤ 6);
- $1 \rightarrow$ vino buono (> 6).

Numero Vini:

- $1 \rightarrow 4113$;
- $0 \rightarrow 2384$

'Notiamo un leggero sbilanciamento'

Cross-validation score:^a

- Accuracy avg: 0.722;


Accuracy del modello dopo addestramento: 0.7053846153846154

^aÈ una tecnica di valutazione che consiste nel dividere il dataset in più sottoinsiemi (fold) e addestrare/testare il modello più volte.


- Stima affidabile della performance del modello su dati non visti
- Riduce il rischio di overfitting (se il modello è troppo bravo sui dati di training, ma pessimo su nuovi dati)

Classe	Precision	Recall	F1-Score	Support
0	0.56	0.75	0.64	451
1	0.84	0.68	0.75	849
Accuracy		0.71		1300
Macro avg	0.70	0.72	0.69	1300
Weighted avg	0.74	0.71	0.71	1300

Table 3: Metriche di valutazione del modello SVM



(a) ROC-AUC Score; valuta la separabilità tra le due classi indipendentemente dal bilanciamento



(b) Precision-Recall; quanto è bravo il modello a riconoscere la classe minoritaria

Figure 2: Metriche in presenza di sbilanciamento




Figure 3: Confusion Matrix - 11 feature




Figure 4: Permutation importance. Elenco Feature per importanza nel definire la qualità del vino

4.5.2 Considerazioni sui risultati ottenuti

Il modello SVM con kernel lineare ha mostrato buone capacità nel classificare la qualità del vino nel dataset *Wine Quality* [1]. In particolare (vedi Figura 2a), l'area sotto la curva ROC (ROC-AUC) pari a 0.78 indica che il classificatore è in grado di distinguere correttamente tra vini di qualità superiore (label > 6) e inferiore (label ≤ 6) nel 78% dei casi, anche in presenza di sbilanciamento tra le classi.

L'analisi della curva Precision-Recall (vedi Figura 2b) ha evidenziato un comportamento asimmetrico tra le due classi:

- **AP0 = 0.50** per la classe negativa: il modello mostra difficoltà nel riconoscere con precisione i vini meno pregiati, suggerendo margini di miglioramento nella gestione della classe minoritaria.
- **AP1 = 0.85** per la classe positiva: il modello risulta affidabile nella classificazione dei vini di qualità superiore, con alta precisione e buon bilanciamento tra recall e precision.

Tali risultati indicano che il modello privilegia la classe positiva, (probabilmente) influenzato dalla distribuzione sbilanciata del dataset. Per migliorare ulteriormente le prestazioni, sarà utile sperimentare kernel **non lineari come RBF**, modificare le soglie decisionali o applicare tecniche di bilanciamento come **SMOTE**.

Nel complesso, il modello lineare fornisce una base solida, ma lascia spazio a strategie per perfezionare la classificazione, soprattutto per la classe meno rappresentata. Infine nella Figura 4, fornisce informazioni sulle feature che realmente sono importanti nell'effettuare la classificazione.

'Possibile che ci sia margine di miglioramento rimuovendo feature che causano rumore e mantenere solo le più importanti?'

4.5.3 Confronto: Modello Completo vs Ridotto

Dalla Figura 4, si è addestrato il modello solo sulle prime due feature.

Sono stati confrontati due modelli SVM con kernel lineare, uno basato su tutte le 11 feature disponibili, l'altro su una selezione di sole 2 feature. I risultati ottenuti mostrano che, pur con una riduzione drastica delle variabili di input, il modello semplificato mantiene prestazioni comparabili su diversi indicatori.

Modello completo (11 feature)

- ROC-AUC = 0.78
- AP0 = 0.50
- AP1 = 0.85
- Accuracy = 0.71
- Cross-validation score = 0.722

Modello ridotto (2 feature)

- ROC-AUC = 0.77
- AP0 = 0.50
- AP1 = 0.85
- Accuracy = 0.70
- Cross-validation score = 0.697

Osservazioni La riduzione delle feature provoca un lieve calo nella performance globale, evidenziato da:

- Diminuzione del ROC-AUC di soli 0.01 punti
- Invarianza dei valori di Average Precision per entrambe le classi
- Riduzione dell'accuracy e dello score di cross-validazione di circa 0.01–0.025 punti

Nonostante ciò, il modello ridotto offre una soluzione più leggera e interpretabile, senza compromettere drasticamente la capacità classificatoria. Ciò suggerisce che le due feature selezionate possiedono un forte potere decisionale sulla qualità del vino e che una modellazione minimalista può essere vantaggiosa in contesti computazionalmente limitati o in fase di interpretazione.




Figure 5: Confusion Matrix - 2 Feature

Osservazioni su Confusion Matrix Osservando le *confusion matrix* in Figura 3 e Figura 5. Il modello ridotto mostra:

- Un leggero miglioramento nei veri negativi (TN): da 338 a 343
- Una diminuzione dei falsi positivi (FP): da 113 a 108
- Un aumento dei falsi negativi (FN): da 270 a 287
- Una diminuzione dei veri positivi (TP): da 579 a 562

Queste variazioni indicano che il modello con 2 feature tende a classificare più correttamente i vini di qualità inferiore (classe 0), ma perde parte della capacità di identificare i vini di qualità superiore (classe 1), aumentando il numero di falsi negativi.

Complessivamente, la differenza è contenuta, e rafforza l'idea che le due feature selezionate possiedono un forte potere decisionale sulla qualità del vino, pur con un compromesso accettabile in termini di performance.

4.5.4 Valutazione SVM Lineare - Classificazione Multiclasse

Al modello SVM con kernel lineare è stato applicato a una **classificazione multiclasse** sulla qualità del vino, suddividendo le etichette in tre classi:

- *low* (0),
- *medium* (1),
- *high* (2).

Il dataset presenta uno sbilanciamento tra le classi, con distribuzione come segue:

Informazioni	
<i>Elementi per classe</i>	
• Classe 1 (medium): 2836 campioni • Classe 0 (low): 2384 campioni • Classe 2 (high): 1277 campioni	
<i>Prestazioni del modello</i>	
• Accuracy del modello: 0.521 • Cross-validation accuracy media: 0.538 • ROC-AUC macro-average (OvR): 0.723	

Confusion Matrix




Figure 6: Confusion Matrix - 11 Feature, Multiclasse

Metriche di classificazione




Figure 7: Precision-Recall - 11 Feature, Multiclasse

- Classe 0 (low):
 - Precisione: 0.58
 - Recall: 0.72
 - F1-score¹: 0.64
 - AP (Average Precision): 0.65
- Classe 1 (medium):
 - Precisione: 0.60
 - Recall: 0.29
 - F1-score: 0.39
 - AP: 0.56
- Classe 2 (high):
 - Precisione: 0.40
 - Recall: 0.72
 - F1-score: 0.51
 - AP: 0.49

¹Metrica molto usata per valutare la qualità di un modello di classificazione, soprattutto quando si vuole tenere conto sia della precisione (quanto i risultati positivi predetti sono corretti) sia del recall (quanti dei positivi reali sono stati effettivamente riconosciuti)

Osservazioni Il modello mostra comportamenti differenti sulle tre classi. La **classe 0** (low quality) viene riconosciuta con buona efficacia (F1-score = 0.64), grazie a un recall elevato, mentre la **classe 1** (medium quality), pur essendo la più numerosa, è la più problematica: il basso recall (0.29) indica difficoltà nel riconoscere i vini medi. La **classe 2** (high quality) ha un buon recall (0.72) ma precisione contenuta (0.40), il che suggerisce un alto tasso di falsi positivi.

La *ROC-AUC macro-average* pari a 0.723 indica una discreta capacità globale del modello di distinguere tra le tre classi, anche se la performance è penalizzata da squilibri nella distribuzione.

Considerazioni Il modello presenta una performance accettabile, ma con chiari limiti nella classificazione della classe intermedia. Questo può essere dovuto a una scarsa separabilità delle caratteristiche oppure alla scelta del kernel lineare. Da questi piccoli confronti, si è notato che il kernel di tipo **lineare** ha portato a risultati, nella media, abbastanza ottimali; questi confronti hanno permesso di comprendere come le relazioni tra le feature siano più complesse di quella lineare.

Il prossimo *step* è quello di testare il nostro modello con kernel=**RBF** ed una selezione delle feature (più importanti).

4.6 Kernel: RBF

Dopo l'addestramento del modello con kernel **lineare**, passiamo all'analisi del **RBF**

4.6.1 Training e Test - *Wine Quality*

Informazioni

Labelling: binario

- $0 \rightarrow$ vino cattivo (≤ 6);
- $1 \rightarrow$ vino buono (> 6).

Numero Vini:

- $1 \rightarrow 4113$;
- $0 \rightarrow 2384$

'Leggero sbilanciamento'

Cross-validation score:

- Accuracy avg: 0.768;

Accuracy del modello dopo addestramento: 0.7661538461538462

Classe	Precision	Recall	F1-Score	Support
0	0.65	0.71	0.68	451
1	0.84	0.79	0.82	849
Accuracy		0.77		1300
Macro avg	0.74	0.75	0.75	1300
Weighted avg	0.77	0.77	0.77	1300

Table 4: Metriche di valutazione del modello SVM




Figure 8: Metriche in presenza di sbilanciamento




Figure 9: Confusion Matrix - 11 feature




Figure 10: Permutation importance

4.6.2 Valutazione

Il modello RBF ha mostrato una performance superiore rispetto al modello lineare in quasi tutte le metriche:

- Il punteggio ROC-AUC è salito a 0.84, indicando una migliore separabilità tra le classi
- L'*AP1* (in Figura 8b), particolarmente elevato (0.89), segnala un'eccellente capacità di identificare i vini di qualità superiore
- Il modello mantiene buon bilanciamento tra precisione e richiamo per entrambe le classi
- La cross-validation conferma la stabilità e generalizzazione del classificatore
- Classificazione più accurata degli errori, ovvero dei **falsi positivi (FP)** e **falsi negativi (FN)**

Il kernel RBF consente al modello di catturare relazioni non lineari tra le caratteristiche chimiche-fisiche del vino, migliorando sensibilmente l'efficacia del processo di classificazione.

Considerazioni Nonostante aver ottenuto un forte miglioramento nella classificazione dei vini, così come per tutte le matriche. Vogliamo però, riuscire a costruire un modello in grado di classificare correttamente i vini di qualità superiore e non. Per garantire un miglior equilibrio tra le classi, l'idea è di passare dall'etichettatura della qualità binaria a quella multiclasse, così come è stato fatto per il *lineare*:

- low,

- medium,
- high

Vogliamo porre l'attenzione alla Figura 10, in cui notiamo che rispetto alla correlazione lineare Figura 1 e Figura 4; l'importanza della Feature nella classificazione è molto diversa. Per **RBF**, tutte le feature hanno molta importanza nel classificare la qualità del vino; in particolare:

- alcohol,
- volatile acidity,

risultano essere le più alte, così come in tutti i grafici analizzati; ma in RBF troviamo anche:

- residual sugar,
- free sulfur dioxide,
- ecc.;

di bassa importanza troviamo:

- chlorides²

4.6.3 Valutazione SVM rbf - Classificazione Multiclasse


L'approccio adottato prevede la classificazione della qualità del vino in tre classi distinte:

- Classe 0 (low)
- Classe 1 (medium)
- Classe 2 (high)


La distribuzione dei campioni nelle classi è risultata bilanciata:

²Avendo un'importanza non elevata ma neanche nulla, la si mantiene come Feature per l'addestramento successivo. La rimozione, porterà solamente ad un lieve miglioramento, quasi impercettibile

Classe	Numero di campioni
0 (low)	2384
1 (medium)	2836
2 (high)	1277



(a) Precision-Recall



(b) Permutation Importance

Figure 11: Metriche, miglioramento dello sbilanciamento

Prestazioni SVM rbf - Classificazione Multiclasse

- Accuracy su test: 0.673
- Cross-validation accuracy media: 0.634
- ROC-AUC macro-average (OvR): 0.828
- Average Precision per classe (Figura 11a):
 - Classe 0: $AP_0 = 0.72$
 - Classe 1: $AP_1 = 0.72$
 - Classe 2: $AP_2 = 0.73$

Confusion Matrix




Figure 12: Confusion Matrix - RBF Multiclasse

4.6.4 Metriche di Classificazione

- **Classe 0 (low):**
 - Precisione: 0.66
 - Recall: 0.68
 - F1-score: 0.67
 - Supporto: 451
- **Classe 1 (medium):**
 - Precisione: 0.66
 - Recall: 0.70
 - F1-score: 0.68
 - Supporto: 597
- **Classe 2 (high):**
 - Precisione: 0.74
 - Recall: 0.59
 - F1-score: 0.65
 - Supporto: 252

4.6.5 Osservazioni

Il modello SVM con kernel RBF ha mostrato una classificazione efficace nelle tre classi definite. Le soglie di etichettatura scelte ($\text{low} \leq 5$, $\text{medium} = 6$, $\text{high} \geq 7$) hanno migliorato la separabilità tra le classi.

In particolare:

- Tutte le classi hanno AP superiori a 0.70, a conferma di una buona precisione media su tutte le soglie.
- La curva ROC presenta un AUC macro pari a 0.828, indicando un'eccellente capacità discriminativa del modello.
- Le metriche F1-score mostrano un comportamento bilanciato tra le classi, con valori vicini tra loro.

Nel complesso, l'approccio multiclasse con kernel RBF risulta superiore rispetto alle versioni binarie precedenti, sia in termini di qualità della classificazione sia in capacità di rappresentazione della varietà del dataset.

4.7 Kernel: Poly

Per curiosità andiamo a sviluppare il modello SVM su kernel **Polinomiale** e classificazione multiclasse; per osservare se possiamo avere dei miglioramenti rispetto al **RBF**.

È stato testato un modello SVM multiclasse con kernel polinomiale (poly) applicato al dataset *Wine Quality*, utilizzando la suddivisione in tre classi: low (0), medium (1), high (2).

4.7.1 Prestazioni

- Accuracy: 0.55
- Macro F1-score: 0.56
- Macro-average ROC-AUC (OvR): 0.755
- Average Precision: $AP_0 = 0.67$, $AP_1 = 0.58$, $AP_2 = 0.53$ (vedi Figura 13b)




Figure 13: Confusion Matrix e Precision Recall

Analisi Il kernel polinomiale ha mostrato performance inferiori rispetto al kernel RBF, sia in termini di accuratezza globale, sia per le metriche specifiche delle classi. In particolare:

- La classe 1 (medium) presenta difficoltà di classificazione, con un recall di 0.39 e F1-score di 0.46 (vedi Figura 13a)
- Le AP scores sono inferiori su tutte le classi rispetto al modello RBF (es. $AP_2 = 0.53$ vs 0.73) (vedi Figura 13b)
- La curva ROC AUC ha valore più basso (0.755 vs 0.828)

4.7.2 Considerazioni

L'utilizzo del kernel RBF si conferma preferibile per questo dataset, in quanto riesce a classificare meglio le decisionali non lineari tra le classi. Il kernel polinomiale può essere utile in situazioni specifiche, ma nel presente caso introduce maggiori errori e squilibri nella classificazione.

4.8 Decision Tree (DT)

Prima di procedere con la costruzione del modello, vogliamo porre l'attenzione sul modello *Decision Tree*.

4.8.1 Configurazione del Modello Decision Tree

Il modello *Decision Tree* è stato utilizzato come approccio alla classificazione della qualità del vino. Di seguito vengono descritti i parametri più rilevanti e il loro ruolo nel controllo della complessità del modello.

Parametri principali

- **criterion**: misura di impurità usata per lo split dei nodi.
 - 'gini': usa l'indice di Gini
 - 'entropy': usa l'entropia dell'informazione
- **max_depth**: profondità massima dell'albero. Limita la crescita per evitare overfitting.
- **min_samples_split**: numero minimo di campioni richiesti per dividere un nodo interno. Valori più alti generano alberi più semplici.
- **min_samples_leaf**: numero minimo di campioni richiesti in una foglia terminale. Previene foglie troppo specifiche.
- **max_features**: limite al numero di feature da considerare in ogni split. Può essere utile per ridurre la varianza.
- **class_weight**: utile nei dataset sbilanciati; l'opzione 'balanced' normalizza i pesi delle classi in base alla loro frequenza.
- **random_state**: semenza per la riproducibilità dei risultati.

4.9 Classificazione Binaria - (DT)

Il modello è stato applicato al dataset *Wine Quality* utilizzando tutte le 11 feature disponibili. La classificazione binaria è stata definita come segue:

- **Classe 0:** qualità ≤ 6
- **Classe 1:** qualità > 6


Sono stati confrontati i risultati ottenuti prima e dopo il tuning dei parametri.

Prestazioni prima del Tuning


- **Accuracy:** 0.739
- **Macro F1-score:** 0.73
- **Weighted F1-score:** 0.74
- **Confusion Matrix:**

$$\begin{bmatrix} 371 & 106 \\ 233 & 590 \end{bmatrix}$$

Prestazioni dopo il Tuning



(a) Metrica ROC e AUC



(b) Precision-Recall

Figure 14: ROC-AUC e Precision Recall

- **Accuracy:** 0.778
- **Macro F1-score:** 0.76

- **Weighted F1-score:** 0.78
- **Confusion Matrix:**
$$\begin{bmatrix} 343 & 134 \\ 155 & 668 \end{bmatrix}$$
- **ROC-AUC (vedi Figura 14a):** 0.77
- **Average Precision (vedi Figura 14b):**
 - AP0 = 0.57
 - AP1 = 0.80

4.9.1 Osservazioni

Il tuning ha portato a un notevole miglioramento delle prestazioni del modello. In particolare:

- La **accuracy** è aumentata di circa 4 punti percentuali
- Il numero di **falsi negativi** è diminuito da 233 a 155, migliorando la capacità del modello di riconoscere i vini di qualità elevata
- Il **ROC-AUC** di 0.77 conferma una buona capacità di differenziare la qualità

Il modello ottimizzato si dimostra più robusto e bilanciato nella classificazione binaria dei vini, confermando l'efficacia del tuning sui parametri dell'albero.




Figure 15: Feature Importance - Decision Tree

Vogliamo porre l'attenzione sull'importanza delle feature per il modello con Albero Decisionale, come evidenziato in Figura 15, vi sono sempre presenti almeno due feature la cui importanza risulta essere inferiore alle altre. Alla luce di

questa osservazione, procediamo con una nuova fase di addestramento del modello, escludendo le feature con importanza marginale.

L'obiettivo di tale approccio è duplice:

- Verificare se la rimozione di variabili non informative possa migliorare le prestazioni del classificatore, riducendo eventuali effetti di rumore o sovradattamento.
- Valutare la robustezza del modello rispetto a una riduzione della dimensionalità, con beneficio in termini di interpretabilità e efficienza computazionale.

Considerazioni su feature limitate Rimuovendo le feature meno importanti:

- *'citric acid'*
- *'fixed acidity'*

si nota un leggero peggioramento del modello, in particolare:

- **Accuracy:** $0.778 \rightarrow 0.766$
- **Macro F1-score:** $0.76 \rightarrow 0.75$
- **Weighted F1-score:** $0.78 \rightarrow 0.77$
- **ROC-AUC:** $0.77 \rightarrow 0.75$
- **Average Precision:**
 - $AP0 = 0.57 \rightarrow 0.57$
 - $AP1 = 0.80 \rightarrow 0.78$

Conviene quindi, mantenere tutte e 11 le feature. I risultati con il set completo sono più solidi e bilanciati.

4.10 Classificazione Muticlasse - (DT)

Il modello è stato impiegato per la classificazione della qualità del vino suddividendo le etichette in tre classi distinte:

- **Classe 0 (low):** punteggio qualità ≤ 5
- **Classe 1 (medium):** punteggio qualità $= 6$
- **Classe 2 (high):** punteggio qualità ≥ 7


Questa suddivisione permette di ottenere una distribuzione *'bilanciata'* e coerente.

Prestazioni prima del Tuning


- **Accuracy:** 0.534
- **Macro F1-score:** 0.53
- **Weighted F1-score:** 0.52
- **Confusion Matrix:**

$$\begin{bmatrix} 302 & 118 & 57 \\ 138 & 189 & 240 \\ 17 & 36 & 203 \end{bmatrix}$$
- **Classe 0 (low):** F1-score = 0.65
- **Classe 1 (medium):** F1-score = 0.42
- **Classe 2 (high):** F1-score = 0.54

Prestazioni dopo il Tuning



(a) Feature Importance - Decision Tree



(b) Precision-Recall

Figure 16: Feature Importance e Precision Recall

- **Accuracy:** 0.645
- **Macro F1-score:** 0.64
- **Weighted F1-score:** 0.65
- **ROC-AUC macro-average (OvR):** 0.728
- **Average Precision (vedi Figura 16b):**

- AP0 = 0.58
- AP1 = 0.56
- AP2 = 0.45

- **Confusion Matrix:**

$$\begin{bmatrix} 329 & 132 & 16 \\ 127 & 351 & 89 \\ 31 & 66 & 159 \end{bmatrix}$$

- **Classe 0 (low):** F1-score = 0.68
- **Classe 1 (medium):** F1-score = 0.63
- **Classe 2 (high):** F1-score = 0.61

4.10.1 Osservazioni

L'ottimizzazione dei parametri ha comportato un miglioramento delle prestazioni del modello, con incremento di **oltre 10 punti percentuali** in accuracy e una maggiore **uniformità tra le tre classi**.

In particolare:

- Le metriche F1-score si sono avvicinate tra loro, dimostrando un migliore bilanciamento nella classificazione
- Il valore di ROC-AUC macro 0.728 conferma una buona capacità discriminativa complessiva
- La suddivisione in tre classi consente una rappresentazione più realistica della qualità del vino, rispetto all'approccio binario

Conclusione La classificazione multiclasse con Decision Tree, se opportunamente ottimizzata, offre una lettura più fedele del dataset, cogliendo le sfumature di qualità con buoni livelli di precisione e recall. Pur essendo meno performante in termini di accuracy assoluta rispetto alla classificazione binaria, l'approccio multi-classe risulta più adatto alle finalità analitiche e descrittive del problema trattato.

5 Conclusioni

Il dataset *Wine Quality*[1] è un ottimo dataset per task di regressione e classificazione, in questo ultimo caso ho avuto modo di mettere in pratica conoscenze apprese durante il corso e nuove per poter costruire un *buon* modello di classificazione della qualità.

Essendo un dataset non bilanciato, ho dovuto sviluppare e pensare a nuove metodologie per poter garantire un equo e più corretto addestramento per il modello così come un testing più accurato; inoltre, un'analisi approfondita sull'importanza delle feature utilizzate per determinare la qualità, tramite tecniche di *feature selection* e confronti tra diversi modelli.

5.1 Classificazione Multiclasse vs Binaria

Nel corso dell'elaborato sono stati sperimentati approcci sia binari che multiclasse per la classificazione della qualità del vino, utilizzando modelli di Support Vector Machine (SVM) e Decision Tree. Di seguito vengono riportate le considerazioni finali sul confronto tra le due strategie.

Classificazione Binaria

La classificazione binaria consiste nella suddivisione dei campioni in due gruppi:

ad esempio, vini “buoni” (qualità > 6) e “non buoni” (qualità ≤ 6).

Vantaggi

- Maggiore semplicità e immediatezza nell'interpretazione dei risultati
- Performance generalmente superiori in termini di accuratezza e F1-score

Svantaggi

- Perdita di informazione: le sfumature qualitative tra vini medi e di alta qualità vengono ignorate
- Minore utilità pratica se l'obiettivo è selezionare prodotti con caratteristiche distintive

Classificazione Multiclasse

La classificazione multiclasse prevede l'identificazione di tre livelli qualitativi:

low, medium e high, con soglia ≤ 5 , $= 6$, ≥ 7

Questa suddivisione è stata adottata in modo coerente sia nei modelli SVM che nel Decision Tree.

Vantaggi

- Maggiore espressività e interpretabilità del risultato
- Capacità di cogliere differenze più sottili tra campioni
- Classificazione applicativa in contesti reali (es. selezione di bottiglie premium)
- Buon bilanciamento tra classi grazie alla scelta ponderata delle soglie di etichettatura

Svantaggi

- Complessità maggiore nel training e nella valutazione
- Sensibilità allo sbilanciamento e possibile calo delle metriche globali (es. accuracy)

5.1.1 Riflessione Finale

I risultati sperimentali indicano che, seppur la classificazione binaria produca metriche superiori in senso assoluto, la classificazione multiclasse risulta più fedele alla struttura del dataset e più utile ai fini descrittivi e decisionali.

In particolare:

- Nel modello SVM con kernel RBF, la multiclasse ha raggiunto valori di ROC-AUC e Average Precision molto elevati e distribuiti in modo uniforme tra le classi
- Nel modello Decision Tree, il tuning ha permesso di ottenere metriche stabili e ben bilanciate tra le tre classi, con F1-score vicini e significativi

Quindi la classificazione multiclasse, grazie alla sua capacità di rappresentare con maggiore precisione le caratteristiche qualitative del vino, costituisce l'approccio preferibile nel presente contesto.

5.2 Considerazioni: SVM

Dalle valutazioni delle prestazioni e del tipo di kernel utilizzato; **RBF** risulta essere ottimo nella classificazione della qualità dei vini dati le caratteristiche chimico-fisiche. In merito all'obiettivo che si vuole raggiungere, le feature presenti nel dataset possono essere tutte in equal modo importanti.

L'obiettivo del contesto attuale è:

1. comparare due modelli su un certo dataset,
2. poter classificare correttamente la qualità dei vini,

nell'ultimo caso, si è notato che riducendo le feature non si è avuto notevoli incrementi nella valutazione del modello.

5.3 Considerazioni: Decision Tree

Il modello del *Decision Tree* ha permesso di esplorare un approccio interpretabile e gerarchico alla classificazione della qualità del vino. I test condotti, sia in configurazione binaria che multiclasse, hanno evidenziato punti di forza e limiti del modello.

Una delle proprietà distintive del Decision Tree è la possibilità di analizzare l'importanza delle feature. L'esperimento di rimozione delle variabili meno influenti non ha comportato un miglioramento nelle performance, segnalando che anche feature marginali possono contribuire alla decisione finale, specialmente in combinazione con altre.

5.4 SVM vs Decision Tree

Nel progetto sono stati analizzati due modelli di classificazione supervisionata: **Support Vector Machine (SVM)** e **Decision Tree**, in configurazione sia binaria sia multiclasse. Entrambi sono stati testati su un dataset reale contenente misurazioni chimico-fisiche dei vini.

Support Vector Machine (SVM) Il modello SVM, in particolare con kernel **RBF**, ha mostrato ottime prestazioni nella classificazione della qualità del vino, grazie alla sua capacità di modellare relazioni non lineari tra le feature.

- Elevata accuracy e F1-score, specialmente nella configurazione multiclasse
- Buoni valori di ROC-AUC e Average Precision su tutte le classi
- Sensibile al tuning dei parametri (es. C , γ), ma capace di generalizzare bene

- Maggiore potenza predittiva rispetto ad altri kernel (es. lineare o polinomiale)

Decision Tree Il modello ad albero decisionale ha offerto una classificazione più interpretabile e trasparente, con risultati solidi sia in versione binaria sia multiclasse.

- Estremamente leggibile: permette di visualizzare il processo decisionale
- Offre analisi diretta dell'importanza delle feature
- Performante nel binario (accuracy fino a 0.778), ma leggermente inferiore nel multiclasse

Confronto e Preferenze Pur riconoscendo che il Decision Tree ha raggiunto performance elevate nella classificazione binaria, l'approccio multiclasse con SVM ha dimostrato una maggiore capacità di catturare le caratteristiche qualitative presenti nel dataset. In particolare:

- L'accurata suddivisione delle classi (**low, medium, high**) ha consentito una segmentazione più realistica dei vini
- Il modello SVM ha mantenuto una maggiore stabilità e precisione anche su classi meno rappresentate
- L'approccio multiclasse, sebbene più complesso, è preferibile per obiettivi di analisi qualitativa e selezione mirata

Conclusione Nel contesto specifico della classificazione della qualità dei vini, si ritiene che il modello SVM con kernel RBF e classificazione multiclasse offra la migliore combinazione tra fase di apprendimento e applicazione pratica. Il Decision Tree invece, resta una scelta valida per scopi interpretativi e di esplorazione.

Bibliografia

- [1] Paulo Cortez et al. “Modeling wine preferences by data mining from physico-chemical properties”. In: *Decision Support Systems* 47.4 (2009), pp. 547–553. URL: <https://archive.ics.uci.edu/dataset/186/wine+quality>.
- [2] Python Software Foundation. *Python 3.12.0 Documentation*. Accessed: 2025-07-14. Python Software Foundation. 2023. URL: <https://docs.python.org/3/>.
- [3] UC Irvine Machine Learning Repository. *UC Irvine Machine Learning Repository*. Accesso: 2 luglio 2025. 2025. URL: <https://archive.ics.uci.edu/>.